# LH 신도시 교통 인프라 데이터 분석을 통한 교통약자 안전 대안 도출

팀명: 천천히, 꾸준히

## 목차


1. 과제 개요
2. 데이터 전처리 및 분석 과정
    - 2-1. 데이터 구성 및 사용 파일
    - 2-2. 정제/가공 절차
    - 2-2-1. 파생 변수 생성 과정
    - 2-2-2. 표기 원칙 (ECR / entropy_composite_risk / 종합위험지수)
    - 2-3. 인프라 변수 정의
    - 2-3-1. 인프라 공백 지표 정의 ( `gap_cnt` )
3. 추가 수집 데이터 설명
4. 최종 결과 도출 과정
    - 4-1. 모델링 프레임
    - 4-2. 통합 가중치 결과
    - 4-3. 종합 위험지수 산출
5. 최종 결과 및 해석
6. 검증 결과
    - 재현성 점검 항목
7. 정책 적용 방안
    - 7-2. 적정 시설물 제안 (하남교산 적용)
8. 한계 및 후속 과제


---

## 1. 과제 개요

본 보고서는 4개 신도시(동탄1·2, 위례, 하남미사, 판교)의 교통사고·교통량·인프라·인구 데이터를 통합 분석하여, 교통약자(어린이·노인 등) 중심의 위험지역을 도출하고 하남교산 적용 대안을 제시하는 것을 목적으로 한다. **본 보고서의 핵심 산출물은 격자별 적정 시설물 제안 지도이다.**

핵심 질문:

- **제한된 예산에서 어떤 안전시설을 어디에 우선 배치해야 하는가?** (본 보고서 핵심)
- 어떤 격자/도로가 실제로 위험한가?
- 위험의 원인은 무엇인가?

---

## 2. 데이터 전처리 및 분석 과정

### 2-1. 데이터 구성 및 사용 파일

#### (1) 입력 데이터 (제공 원시 데이터)

| 번호 | 파일명 | 형식 |
|---|---|---|
| 01 | 격자 (4개 시·구) | geojson |
| 02 | 격자 (하남교산) | geojson |
| 03 | 성연령별 거주인구(격자) | csv |
| 04 | 성연령별 유동인구 | csv |
| 05 | 시간대별 직장인구 | csv |
| 06 | 시간대별 방문인구 | csv |
| 07 | 주중주말 서비스인구 | csv |
| 08 | 상세도로망 네트워크 | geojson |
| 09~13 | 교통량/속도/혼잡/교통사고이력 데이터 | csv/geojson |
| 14~21 | 인프라 현황 (어린이보호구역, 학교, 유치원, 어린이집, 횡단보도, 버스정류장, CCTV, 과속방지턱) | csv |

**데이터 기간:** 교통사고이력 데이터는 2024년 1년치를 사용하였다. 인구·인프라·교통량·혼잡 데이터는 동일 시점 또는 최근 시점 기준으로 제공받았다.

#### (2) 분석 산출 파일

- `00_교통사고_링크매핑.csv`
- `00_링크별_사고집계.csv`
- `00_격자별_통합데이터.csv`
- `01_사고별_EPDO점수.csv`
- `02_링크별_교통량.csv`
- `03_링크별_위험도.csv`
- `04_위험도로_원인분석.csv`
- `05_격자별_EPDO_인프라통합.csv`
- `06_인프라_상관분석.csv`
- `07_ML_위험도예측.csv`
- `08_격자_종합위험지수.csv`
- `08_하남교산_예측위험도.csv`
- `08_하남교산_격자별_ECR_최종.csv`
- `09_엔트로피_가중치.csv`
- `10_통합가중치_최종.csv`
- `11_시설물설치_효과예측.csv`

## 2-2. 정제/가공 절차

분석은 `link_id` (도로 단위)와 `grid_gid` (100m 격자 단위)를 병행하여 수행했다.

1. 사고 심각도 표준화(EPDO) > EPDO란? Equivalent Property Damage Only의 약자로, 사고의 심각도(사망·중상·경상 등)를 하나의 숫자로 환산한 지표이다. 예를 들어 사망사고 1건은 경미한 물적피해 391건과 같은 수준의 위험으로 본다.

$$\text{EPDO_}i = \sum_k(w_k \times n_ik)$$

- $n_ik$ : 구간 i에서 발생한 심각도 k 사고 건수
- $w_k$ : 사고 심각도에 대한 가중치
- $k \in$ {사망, 중상, 경상, 부상신고, 상해없음, 기타불명}

EPDO 가중치:

| 심각도 | 가중치 | 비고 |
|---|---|---|
| 사망 | 391 | PDO 391건 상당 |
| 중상 | 69 | PDO 69건 상당 |
| 경상 | 8 | PDO 8건 상당 |
| 부상신고 | 6 | |
| 상해없음(PDO) | 1 | 기준값 |
| 기타불명 | 8 | 경상과 동일, 보수적 처리 |

가중치 산출 근거:

> 이상엽(2019). 「교통사고 원인행위의 벌점 추정에 관한 연구」, 대한교통학회지, 37(5), 365-378.
>
> 해당 연구는 사고 심각도별 사회적 비용을 물적피해(PDO) 1건 대비 상대 비율로 환산한 것이다. 즉, 사망 1건의 사회적 비용은 물적피해 391건에 해당하며, 중상 1건은 물적피해 69건, 경상 1건은 물적피해 8건에 해당한다. 이를 통해 사고 건수 단순 합산의 편향을 보정하고, 심각도를 반영한 단일 지표(EPDO)로 통일했다.

2. 도로(링크) 단위 위험도 산출

- 도로의 노출량(= 연평균 일교통량 × 도로 길이)을 고려하여, 교통량 대비 사고 심각도 비율( `epdo_rate` )을 산출했다.
- 이를 통해 "교통량이 많아서 사고 건수가 많아 보이는 도로"와 "진짜 위험한 도로"를 구분했다.

3. 격자 단위 통합

- 사고, 인프라(14~21), 인구(03~07), 속도/혼잡(09/11/12) 데이터를 100m 격자( `grid_gid` ) 기준으로 하나로 합쳤다.
- 값이 비어 있는 경우(결측)에는 0 또는 해당 변수의 평균값으로 채워 넣었다.

4. 공간 처리 (지도 위에서 데이터 연결)

- 사고 발생 지점(점 데이터)은 해당 위치가 속하는 격자 칸에 배정했다.
- 도로(선 데이터)는 격자 칸과 겹치는지 여부로 연결하여, 데이터 누락을 최소화했다.

5. 품질 점검

- 데이터가 정상적으로 연결되었는지(매칭률), 빠진 값이 얼마나 되는지(결측률)를 확인했다.
- 값의 범위가 비정상적이지 않은지(음수 발생, 극단적 이상값 등)를 점검했다.

### 2-2-1. 파생 변수 생성 과정

본 연구에서는 제공받은 원시 데이터를 가공하여, 교통약자 위험도를 설명할 수 있는 7개의 새로운 지표(파생 변수)를 만들었다.

> 격자(grid)란? 분석 대상 지역을 100m × 100m 정사각형으로 나눈 단위이다. 각 격자마다 사고·인구·인프라 정보를 집계하여 비교한다.

1. 노인 거주 비율 ( `elderly_res_ratio` ) `03_성연령별_거주인구(격자).csv` 에서 격자별 60대 이상 거주인구와 전체(20대 이상) 거주인구를 합산하여 비율을 산출하였다.

$$\text{elderly_res_ratio} = \frac{\text{elderly_res_pop}}{\text{total_res_pop}}$$

- elderly_res_pop = 60대~100대 이상 남녀 합산 (m_60g_pop + w_60g_pop + ⋯ + m_100g_pop + w_100g_pop)
- total_res_pop = 20대~100대 이상 남녀 합산

2. 교통약자 유동 비율 ( `vuln_float_ratio` ) `04_성연령별_유동인구.csv` 의 위치 좌표(경도, 위도)가 어느 격자 칸에 속하는지를 판별하여, 격자별 어린이(10대)·고령자(60대 이상) 유동인구 비율을 산출하였다.

$$\text{vuln_float_ratio} = \frac{\text{child_float} + \text{elderly_float}}{\text{total_float}}$$

- child_float = m_10g_pop + w_10g_pop
- elderly_float = m_60g_pop + w_60g_pop
- total_float = 10대~60대 이상 전체 남녀 합산 (12개 컬럼)

3. 취약시간대 교통약자 인구 ( `vuln_peak_pop` ) 어린이·고령자가 도로에 노출되는 시간대를 등교(07–09시), 하교(13–16시), 퇴근(17–19시) 총 10개 시간대로 정의하고, `05_시간대별_직장인구.csv` 와 `06_시간대별_방문인구.csv` 에서 해당 시간대 인구를 격자별로 합산하였다.

$$\text{vuln_peak_pop} = \text{vuln_work} + \text{vuln_visit}$$

- vuln_work = Σ TMST_{h} (직장인구), h ∈ {07, 08, 09, 13, 14, 15, 16, 17, 18, 19}
- vuln_visit = Σ TMST_{h} (방문인구), 동일 시간대

직장·방문인구 데이터는 수백만 행에 달하므로, 3만 행씩 나누어(청크 처리) 각 사람의 좌표가 속하는 격자를 찾아 합산하였다.

4. 주말 방문 비율 ( `weekend_ratio` ) `07_주중주말_서비스인구.csv` 를 `hw` 컬럼 기준으로 주중(H)/주말로 분리한 뒤, 방문인구( `v_pop` )를 격자별 합산하여 주말 비율을 산출하였다.

$$\text{weekend_ratio} = \frac{\text{weekend_visit}}{\text{weekday_visit} + \text{weekend_visit}}$$

5. 격자 평균 속도 ( `grid_avg_speed` ) `08_상세도로망_네트워크.geojson` 에서 각 도로 구간이 어떤 격자 칸을 지나가는지를 판별한 뒤, 격자 안을 통과하는 모든 도로의 평균속도를 평균 내어 해당 격자의 대표 속도로 사용하였다.

$$\text{grid_avg_speed} = \frac{1}{|L_i|} \sum_{l \in L_i} \text{avg_speed}_l$$

- $L_i$ : 격자 $i$와 교차하는 도로 링크 집합 (avg_speed > 0인 링크만)

속도 측정 기록이 없는 격자는, 해당 격자를 지나는 도로의 등급(고속도로/국도/지방도 등)에 따른 전체 평균속도를 대신 사용하였다.

6. 격자 혼잡위험도 ( `grid_congestion` ) 각 도로 링크의 혼잡위험도는 11·12번 혼잡 데이터(FRIN_CG, TI_CG)를 이용하여 다음과 같이 산출하였다.

$$\text{congestion_risk}_l = \frac{\text{FRIN_CG}_l \times \text{TI_CG}_l}{100}$$

- FRIN_CG: 혼잡이 얼마나 자주 발생하는지 (0–100)
- TI_CG: 혼잡이 얼마나 오래 지속되는지 (0–100)

이를 격자 안을 지나는 모든 도로에 대해 평균을 구하였다.

$$\text{grid_congestion} = \frac{1}{|L_i|} \sum_{l \in L_i} \text{congestion_risk}_l$$

7. 인프라 공백 수 ( `gap_cnt` ) 아래 2-3-1절에서 별도로 정의한다.

### 2-2-2. 표기 원칙 (ECR / entropy_composite_risk / 종합위험지수)

본 보고서에서 **종합위험지수**, **ECR**, **entropy_composite_risk**는 동일한 지표를 가리킨다. 산식은 $\text{EPDO}_i \times (1 + \text{correction_index}_i)$이며, 4-3-1절에서 상세히 정의한다. 사용처에 따라 다음과 같이 표기한다.

| 용어 | 사용처 |
|---|---|
| 종합위험지수 | 일반 설명, 정책 문맥 |
| ECR | 표·파일명·간단한 언급 (Entropy Composite Risk 약자) |
| entropy_composite_risk | 산식·코드·CSV 컬럼명 |

## 2-3. 인프라 변수 정의(데이터 14~21)

| 변수명 | 설명 | 데이터 번호 |
|---|---|---|
| child_zone_cnt | 어린이보호구역 수 | 14 |
| school_cnt | 학교 수 | 15 |
| kindergarten_cnt | 유치원 수 | 16 |
| daycare_cnt | 어린이집 수 | 17 |
| crosswalk_cnt | 횡단보도 수 | 18 |
| bus_stop_cnt | 버스정류장 수 | 19 |
| cctv_cnt | CCTV 카메라 수 | 20 |
| speedbump_cnt | 과속방지턱 수 | 21 |

해석: 각 격자 안에 안전시설이 얼마나 갖추어져 있는지를 나타내는 지표로 사용하였다.

### 2-3-1. 인프라 공백 지표 정의 ( `gap_cnt` )

안전시설이 얼마나 부족한지를 숫자로 표현하기 위해, 안전시설 6종을 대상으로 인프라 공백 지표를 정의하였다.

대상 시설(안전시설):

| 변수명 | 시설명 |
|---|---|
| crosswalk_cnt | 횡단보도 |
| child_zone_cnt | 어린이보호구역 |
| speedbump_cnt | 과속방지턱 |
| cctv_cnt, cctv_cam_cnt | CCTV 계열 인프라 |
| bus_stop_cnt | 버스정류장 |

> 교육시설 제외 이유: 학교·유치원·어린이집은 어린이가 모이는 곳이라 오히려 통행이 많아진다. 따라서 "안전을 지키는 시설"이 아니라 "위험을 유발하는 시설(어린이 통행 발생원)"로 보아, 인프라 공백 개수 산정에서 제외하였다.

판정 기준:

- 시설 수 = 0 → 없음 (공백)
- 시설 수 < 전체 격자 평균의 50% → 부족 (공백)
- 그 외 → 정상

$$\text{gap_cnt}_i = \sum_{k=1}^{6} I(\text{시설}_k \text{ 공백 여부})$$

$$I(x) = \begin{cases} 1 & \text{시설 없음 또는 부족} \\ 0 & \text{시설 존재} \end{cases} \quad (\text{지시함수: 조건 만족 시 } 1\text{, 아니면 } 0)$$

즉, 해당 격자에 안전시설이 존재하지 않거나 현저히 부족한 경우 공백으로 계산하며, gap_cnt의 범위는 0~6이다. 이 지표는 이후 종합 위험지수의 보정계수(correction_index)와 시설 제안 로직에 직접 활용된다.

---

## 3. 추가 수집 데이터 설명

본 제출본은 제공 데이터와 내부 전처리 산출물만 사용했다.

- 외부 추가 수집 데이터: 없음
- 웹 크롤링 데이터: 없음
- 외부 논문/통계: EPDO 가중치 해석 근거로만 사용, 모델 입력 데이터로는 사용하지 않음

---

## 4. 최종 결과 도출 과정

### 4-1. 모델링 프레임

최종 위험도는 세 가지 서로 다른 통계 기법의 결과를 합쳐서(3중 통합 가중치) 산출했다. 하나의 방법에만 의존하면 편향이 생길 수 있으므로, 세 방법의 장점을 고루 반영하기 위함이다.

- `w_nb` — 음이항 회귀(사고 건수를 예측하는 통계 모델)가 판단한 각 변수의 중요도
- `w_corr` — 각 변수와 사고 심각도(EPDO)의 상관관계 크기
- `w_entropy` — 격자 간 값의 차이가 큰 정도(엔트로피 방식)로 측정한 변수의 구분력

세 가중치를 기하평균(곱한 뒤 세제곱근)으로 합산한 후, 합이 100%가 되도록 정규화한다.

$$w_\text{raw}, i = (w_\text{nb}, i \times w_\text{corr}, i \times w_\text{entropy}, i)^{1/3}$$

$$w_\text{final}, i = \frac{w_\text{raw}, i}{\sum_j w_\text{raw}, j}$$

#### 4-1-1. 음이항 회귀 모델 선택 이유

교통사고 건수는 0, 1, 2, 3… 과 같이 정수로만 나타나는 데이터이다. 이런 데이터에는 보통 포아송(Poisson) 회귀가 쓰이는데, 포아송 모델은 “데이터의 평균과 흩어진 정도(분산)가 비슷하다”는 가정이 있다.

그런데 실제 데이터를 보면, 대부분의 격자는 사고가 적고 일부 격자에만 사고가 집중되어 데이터가 평균보다 훨씬 넓게 퍼져 있는 현상(과산포, over-dispersion) 이 나타났다.

| 통계량 | 값 |
|---|---|
| 격자 수 (N) | 1,481 |
| 사고 건수 평균 | 2.91 |
| 사고 건수 분산 | 7.93 |
| 분산/평균 비 | 2.73 |

분산(7.93)이 평균(2.91)의 약 2.7배로, 포아송 모델의 “평균 ≈ 분산” 가정에 맞지 않는다. 따라서 이런 과산포 상황에 적합한 음이항 회귀(Negative Binomial Regression) 를 적용하였다.

> 음이항 회귀란? 포아송 모델을 확장한 것으로, “눈에 보이지 않는 격자 간 차이”까지 고려하여 사고 건수를 더 정확하게 설명할 수 있는 통계 모델이다.

$$\text{Var}(Y) = \mu + \alpha\mu^2$$

- $\mu$ : 조건부 평균 (포아송 부분)
- $\alpha$ : 과산포 파라미터 ( $\alpha > 0$ 이면 과산포)

예측하려는 값(종속변수)은 격자별 사고 건수이며, 원인이 되는 변수(독립변수)는 `2-2-1절` 에서 정의한 7개 파생 변수를 평균 0·표준편차 1로 맞춘 뒤(표준화) 투입하였다.

## 4-2. 통합 가중치 결과

`10_통합가중치_최종.csv` 기준:

| 순위 | 인자 | 통합 가중치 |
|---|---|---|
| 1 | vuln_peak_pop | 51.03% |
| 2 | gap_cnt | 13.18% |
| 3 | grid_avg_speed | 8.85% |
| 4 | elderly_res_ratio | 8.80% |
| 5 | weekend_ratio | 7.43% |
| 6 | grid_congestion | 6.33% |
| 7 | vuln_float_ratio | 4.38% |

### 4-2-1. 개별 가중치 산출 방법

1. 엔트로피 가중치 ( $w_\text{entropy}$ ) > 엔트로피란? 데이터가 얼마나 고르게 분포되어 있는지를 측정하는 지표이다. 값이 격자마다 크게 다르면(변별력이 높으면) 가중치가 커진다.

격자 간 변동이 클수록 구분력이 높다는 원리.

$$x'_ij = \frac{x_ij - \min}{\max - \min} \quad (\text{정규화})$$

$$p_ij = \frac{x'_ij}{\sum_ix'_ij} \quad (\text{비율})$$

$$e_j = -\frac{1}{\ln n} \sum_i(p_ij \times \ln p_ij) \quad (\text{엔트로피})$$

$$w_j = \frac{1 - e_j}{\sum_j(1 - e_j)} \quad (\text{가중치})$$

2. 음이항 회귀 가중치 ( $w_\text{nb}$ ) 사고건수를 종속변수로 음이항 회귀 수행.

$$X_j, \text{std} = \frac{X_j - \mu_j}{\sigma_j} \quad (\text{표준화})$$

$$\ln(\mu) = \beta_0 + \sum_j\beta_j \times X_j, \text{std} \quad (\text{모델})$$

$$w_j = \frac{|\beta_j|}{\sum_j|\beta_j|} \quad (\text{가중치})$$

3. EPDO 상관계수 가중치 ( $w_\text{corr}$ ) 각 변수가 사고 심각도(EPDO)와 얼마나 같이 움직이는지(상관관계)를 측정하여 가중치로 변환하였다.

$$w_j = \frac{|r_j|}{\sum_j|r_j|}$$

#### 4-2-2. 통합 (세 가중치를 하나로 합침)

$$w_\text{raw}, j = (w_\text{nb}, j \times w_\text{corr}, j \times w_\text{entropy}, j)^{1/3}$$

$$w_\text{final}, j = \frac{w_\text{raw}, j}{\sum_j w_\text{raw}, j}$$

예) `vuln_peak_pop` 기하평균 계산 과정:

1. 세 방법 가중치 곱의 세제곱근: $w_\text{raw} = (0.4719 \times 0.4005 \times 0.3478)^{1/3} = 0.4035$
2. 7개 인자 raw 합: $\sum_j w_\text{raw}, j = 0.7908$
3. 정규화: $0.4035/0.7908 = 0.5103 = 51.03\%$

> 개별 raw 값은 아래 표의 NB회귀·EPDO상관·엔트로피 비율을 소수로 환산한 뒤, 각 인자별로 곱한 값의 세제곱근이다. 전체 raw 합계(0.7908)로 나누면 합이 100%가 된다.

개별 가중치 상세표:

| 인자 | NB회귀 | EPDO상관 | 엔트로피 | 통합 |
|---|---|---|---|---|
| vuln_peak_pop | 47.19% | 40.05% | 34.78% | 51.03% |
| gap_cnt | 20.77% | 22.15% | 2.46% | 13.18% |
| grid_avg_speed | 12.73% | 5.14% | 5.25% | 8.85% |
| elderly_res_ratio | 1.49% | 4.77% | 47.53% | 8.80% |
| weekend_ratio | 9.72% | 8.38% | 2.49% | 7.43% |
| grid_congestion | 3.21% | 5.69% | 6.87% | 6.33% |
| vuln_float_ratio | 4.90% | 13.82% | 0.62% | 4.38% |

### 4-3. 종합 위험지수 산출

격자별 최종 위험도는 `08_격자_종합위험지수.csv` 의 종합지수( `entropy_composite_risk` )를 기준으로 순위를 부여했다.

#### 4-3-1. 종합 위험지수 계산 방식

종합 위험지수( `entropy_composite_risk` )는 사고 심각도(EPDO)에 주변 환경 보정값을 더하는 방식으로 산출하였다. 사고가 심각한 곳일수록 기본 점수가 높고, 노인 밀집·인프라 부족 등 환경이 나쁠수록 추가 점수가 붙는 구조이다.

① 보정지수 산출 ( `correction_index` ) 7개 파생 변수(2-2-1절 참조)를 모든 격자 중 최솟값=0, 최댓값=1이 되도록 0~1 범위로 환산(min-max 정규화) 한 뒤, 각 변수의 중요도(엔트로피 가중치)를 곱해서 합산한다.

$$X'_ij = \frac{X_ij - \min(X_j)}{\max(X_j) - \min(X_j)}$$

$$\text{correction_index}_i = \sum_{j=1}^{7} w_{\text{entropy},j} \times X'_{ij}$$

| 인자 ( $j$ ) | 엔트로피 가중치 ( $w_\text{entropy}, j$ ) |
|---|---|
| elderly_res_ratio | 0.4753 (47.53%) |
| vuln_peak_pop | 0.3478 (34.78%) |
| grid_congestion | 0.0687 (6.87%) |
| grid_avg_speed | 0.0525 (5.25%) |
| weekend_ratio | 0.0249 (2.49%) |
| gap_cnt | 0.0246 (2.46%) |
| vuln_float_ratio | 0.0062 (0.62%) |

> 여기서 사용하는 가중치는 엔트로피 방법 단독으로 산출한 값이며, 4-2절의 "세 방법 통합 가중치"와는 다른 값이다. 통합 가중치는 변수 순위 결정에, 엔트로피 단독 가중치는 위험지수 보정에 각각 쓰인다.

② 종합 위험지수 산출

$$\text{entropy_composite_risk}_i = \text{EPDO}_i \times (1 + \text{correction_index}_i)$$

- EPDO가 높을수록(사고가 심각할수록) 기본 위험 점수가 높다
- 보정지수가 클수록(노인 밀집, 등하교 시간대 인구 많음, 안전시설 부족 등) 위험 점수가 추가로 올라간다
- 보정지수의 범위는 0~1이므로, 최대 2배까지 점수가 높아질 수 있다

③ 산출 예시

| 항목 | 값 |
|---|---|
| 격자 다사672368의 EPDO | 531.0 |
| elderly_res_ratio 정규화값 × 가중치 | 0.4753 × 0.67 = 0.318 |
| vuln_peak_pop 정규화값 × 가중치 | 0.3478 × 0.52 = 0.181 |
| (나머지 5개 인자 합산) | 0.109 |
| correction_index | 0.608 |
| entropy_composite_risk | 531.0 × (1 + 0.608) = 854.04 |

위험등급 분류:

4개 신도시 1,481개 격자의 종합위험지수를 점수 순으로 정렬했을 때, 상위 25%에 드는 경계값이 111.12, 하위 25% 경계값이 77.38이다. 이를 기준으로 등급을 나눴다.

| 등급 | 기준 |
|---|---|
| 고위험 | 111.12 이상 (상위 25%) |
| 중위험 | 77.38 이상 111.12 미만 (중간 50%) |
| 저위험 | 77.38 미만 (하위 25%) |

위험등급 분포:

| 구분 | 고위험 | 중위험 | 저위험 | 합계 |
|---|---|---|---|---|
| 4개 신도시 (사고발생 격자) | 371 | 740 | 370 | 1,481 (동일 점수 경계값 처리로 1건 제외) |
| 하남교산 (사고발생 격자) | 9 | 0 | 32 | 41 |

[4개 신도시] 상위 격자 (엔트로피 종합위험지수 기준)

| 순위 | grid_gid | 위험지수 |
|---|---|---|
| 1 | 다사672368 | 854.04 |
| 2 | 다사675380 | 790.36 |
| 3 | 다사671371 | 735.16 |
| 4 | 다사685437 | 713.68 |
| 5 | 다사672369 | 662.32 |

[하남교산 적용대상지] 상위 격자 (엔트로피 종합위험지수 기준)

| 순위 | grid_gid | 위험지수 |
|---|---|---|
| 1 | 다사738470 | 310.16 |
| 2 | 다사757484 | 192.31 |
| 3 | 다사728472 | 189.01 |
| 4 | 다사745480 | 169.37 |
| 5 | 다사751480 | 159.48 |

> 하남교산 사고발생 41개 격자는, 교통사고 발생 지점이 어느 격자 칸에 속하는지를 판별하여 도출했으며, 위험등급은 4개 신도시와 동일한 기준을 적용했다.

---

## 5. 최종 결과 및 해석

### 5-1. 주요 수치 결과

- 사고 건수(사고 레코드): 10,865건 ( `01_사고별_EPDO점수.csv` )
- 종합위험지수 산출 격자 수(4개 신도시): 1,481개 ( `08_격자_종합위험지수.csv` )
  - 위험등급 분포: 고위험 371개 / 중위험 740개 / 저위험 370개
  - 등급 기준: 111.12 이상 = 고위험(상위 25%) / 77.38~111.12 = 중위험(중간 50%) / 77.38 미만 = 저위험(하위 25%)

- `entropy_composite_risk` 정의: 격자별 사고 심각도(EPDO)에 환경 보정을 곱한 종합 위험지수. 산식은 $\mathrm{EPDO}_i \times (1 + \mathrm{correction_index}_i)$이며, `correction_index` 는 7개 파생 변수(노인 비율, 취약시간대 인구 등)를 min-max 정규화한 뒤 엔트로피 가중치로 가중합산한 값이다. 상세 로직은 4-3-1절 참조.
- 하남교산 블록유형 기반 예측 격자 수: 770개 ( `08_하남교산_예측위험도.csv` )
  - 위험등급 분포: 고위험 85개 / 중위험 558개 / 저위험 127개
  - 등급 기준: blockType별 동일유형 패턴 매칭 기반 pred_risk 분류
- 하남교산 사고발생 격자 수: 41개 ( `08_하남교산_격자별_ECR_최종.csv` )
  - 추출 기준: `accident_cnt > 0` (해당 격자에 교통사고가 1건 이상 발생한 경우). 하남교산 격자(770개)와 교통사고이력을 공간조인(point-in-polygon)한 결과, 실제 사고가 발생한 격자는 41개(총 118건)이다.
  - 위험등급 분포(entropy_composite_risk 기준, 4개 신도시 동일 임계값 적용): 고위험 9개 / 중위험 0개 / 저위험 32개
- **하남교산 적정 시설물 제안** ( `08_하남교산_사고격자_시설제안.csv` , `12_facility_recommendation` ): 41개 격자에 격자별 시설 제안 도출. 방지턱+노면표시 26개소, 어린이보호구역 보강 4개소, 스마트 횡단보도 4개소, 지능형 CCTV 1개소 등. 7-2절 지도 2 참조.

### 5-2. 해석

1. 취약시간대 인구 영향이 가장 큼

- `vuln_peak_pop` 이 모든 방법에서 상위로 나타나, 시간대 기반 개입(등하교/퇴근 시간)이 핵심임을 확인했다.

2. 안전시설 부족은 사고 위험과 실제로 관련이 있음

- 엔트로피 방법에서는 중요도가 낮게 나왔지만, 음이항 회귀와 상관분석에서는 일관되게 유의미한 결과가 나왔다.
- 따라서 위험이 높으면서 안전시설이 부족한 격자를 우선 보강하는 전략이 타당하다.

3. 노인 거주 밀집은 구조적 위험 요인

- `elderly_res_ratio` 가 엔트로피 기준 핵심 변수로 확인되며, 고령자 보행 동선 중심 정책 설계가 필요하다.

---

## 6. 검증 결과

단순 사고 심각도(EPDO) 순위와 종합 위험지수(entropy_composite_risk) 순위가 얼마나 일치하는지를 비교하여, 종합 위험지수가 실제 사고 위험을 잘 반영하는지 검증하였다 (4개 신도시 1,481개 격자 대상).

| 검증 항목 | 결과 | 의미 |
|---|---|---|
| 상위 5% 격자 일치율 | 72/74 = 97.30% | 가장 위험한 격자를 거의 동일하게 식별 |
| 상위 10% 격자 일치율 | 134/150 = 89.33% | 10%까지 넓혀도 높은 일치 |
| 상위 20% 격자 일치율 | 282/297 = 94.95% | 광범위에서도 안정적 |
| 순위 상관계수 (Spearman) | 0.9197 | 1에 가까울수록 순위가 일치 (0.92 = 매우 높음) |

해석:

- 종합 위험지수 상위 격자와 실제 사고 심각도 상위 격자가 90% 이상 일치하여, 위험 지역을 정확하게 식별하고 있으며 정책 우선순위 도구로 신뢰할 수 있다.

### 재현성 점검 항목

분석 재현 및 활용 시 아래 항목을 관리한다.

| 항목 | 관리 기준 |
|---|---|
| 입력 데이터 | 01~21번 원시 파일, 버전·수집 시점 명시 |
| 처리 순서 | 2-2절 정제/가공 절차 순서 준수 |
| 필터 | 사고발생 격자: `accident_cnt > 0` |
| 임계값 | 위험등급: 상위 25% 경계 111.12, 하위 25% 경계 77.38 (4개 신도시 1,481격자 기준) |
| 검증 지표 | 상위 5/10/20% 일치율, Spearman 순위 상관계수 |

다른 지역·시점에 적용 시 임계값 재보정이 필요하다(8장 한계 참조).

---

## 7. 정책 적용 방안

### 7-1. 스마트 교통시설 설치 의사결정 규칙

| 시설물 | 설치 조건 | 설치 위치 | 기대 효과 |
|---|---|---|---|
| 스마트 횡단보도 | crosswalk_cnt=0, 보행자 사고/어린이·노인 유동 높음 | 학교·유치원 200m 내, 하교 시간대 사고 집중 격자 | 보행자 충돌 위험 저감 |
| 지능형 CCTV | CCTV 계열 인프라 부족 + 야간/주말 사고 비율 높음 | 교차로 진입부, 버스정류장 인접 격자 | 위반 억제 및 사후 대응 강화 |
| 우회전 경고 전광판 | 차대사람·우회전 관련 위반 빈도 높음 | 우회전 동선 교차점 | 우회전 보행자 사고 예방 |
| 가드펜스/보행분리시설 | 보차분리 취약 + 속도 높음 | 통학로 외곽부/교차로 접근로 | 보행공간 침범 감소 |
| 과속저감 패키지(방지턱+노면표시) | speedbump_cnt=0, 고속/직선 구간 | 학교 앞, 생활도로 진입부 | 접근속도 저감 |

### 7-2. 하남교산 적용 결과 및 적정 시설물 제안

**본 절의 핵심은 격자별 적정 시설물 제안이다.** 4개 신도시에서 발견한 “어떤 조건이 위험한가” 패턴을 하남교산에 적용하여, 위험도 분석 → 인프라 공백 식별 → **격자별 시설물 제안**까지 일관된 흐름으로 도출했다.

하남교산 위험도 평가는 두 가지 기준으로 수행했다.

① 사고 기반 분석 — 실제로 사고가 발생한 41개 격자를 대상으로, 4개 신도시와 동일한 ECR 기준(상위 25% 경계 111.12, 하위 25% 경계 77.38) 적용
→ 고위험 9개 / 중위험 0개 / 저위험 32개

② 토지이용 유형 기반 예측 — 하남교산 전체 770개 격자를 대상으로, “4개 신도시에서 같은 종류의 땅(주거지, 상업지 등)이 얼마나 위험했는지”를 기준으로 예측
→ 고위험 85개 / 중위험 558개 / 저위험 127개

**정책 적용 시 판단 기준:** 사고가 발생한 격자(41개)는 ① 사고 기반 결과를 우선 사용한다. 사고가 없는 격자(729개)는 ② 토지 이용 기반 예측 결과로만 평가한다. 즉, ①은 “실제 사고가 난 곳”의 위험도를, ②는 “아직 사고는 없지만 유사 환경에서 위험했던 곳”의 예측 위험도를 보여준다. 두 결과를 통합할 때는 ①의 41개 격자를 기준으로 즉시 개입하고, ②의 고위험 85개 격자 중 41개와 겹치지 않는 구간은 선제 배치 후보로 활용한다.

*지도 1. 교통사고 발생구역의 위험도*

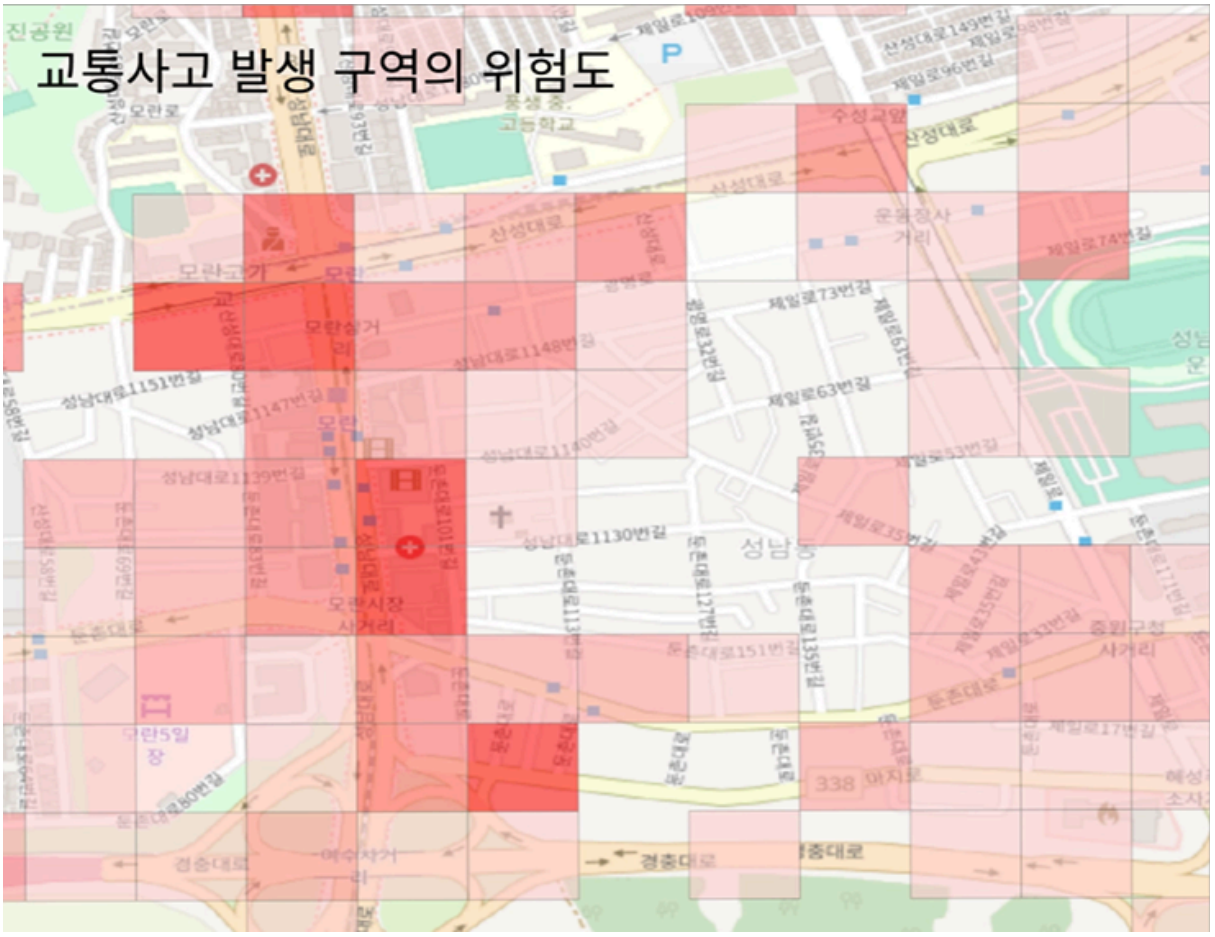


교통사고 발생 구역의 위험도

### (1) 분석대상지(4개 신도시) 고위험 격자 Top 10 — 모델 산출 근거

출처: `08_격자_종합위험지수.csv` + `11_시설물설치_효과예측.csv`

| grid_gid | 위험 순위 | 위험 지수 | 핵심 인프라 공백 | 제안시설 | 우선순위 |
|---|---|---|---|---|---|
| 다사672368 | 1 | 854.04 | child_zone, speedbump, bus_stop 없음 | 우회전 경고 전광판 + 과속저감 + 버스정류장 연계 보행안전 | 1 |
| 다사675380 | 2 | 790.36 | crosswalk, child_zone 없음 | 스마트 횡단보도 + 보호구역 보강 | 2 |
| 다사671371 | 3 | 735.16 | child_zone, speedbump, bus_stop 없음 | 보호구역 + 과속저감 + 보행동선 분리 | 3 |
| 다사685437 | 4 | 713.68 | child_zone 없음 | 보호구역 지정 + 시인성 강화시설 | 4 |
| 다사672369 | 5 | 662.32 | crosswalk, child_zone, speedbump 없음 | 스마트 횡단보도 + 보호구역 + 과속저감 | 5 |
| 다사696385 | 6 | 661.12 | 6종 전부 없음 | 스마트 횡단보도 + 지능형 CCTV + 과속저감(집중투자) | 6 |
| 다사661445 | 7 | 657.67 | child_zone, CCTV 계열 인프라 없음 | 지능형 CCTV + 보호구역 보강 | 7 |
| 다사645448 | 8 | 580.00 | child_zone, CCTV 계열 인프라 없음 | CCTV + 보호구역 보강 | 8 |
| 다바374949 | 9 | 578.53 | child_zone, speedbump, CCTV 계열 인프라, bus_stop 없음 | CCTV + 과속저감 + 버스정류장 연계 보행정비 | 9 |
| 다사661436 | 10 | 538.13 | child_zone, speedbump, bus_stop 없음 | 보호구역 + 과속저감 + 보행 대기공간 정비 | 10 |

### (2) 하남교산 사고발생 격자 Top 10 — ECR 산출 결과

출처: `08_하남교산_격자별_ECR_최종.csv` (하남교산 사고발생 격자 41개 중 위험지수 상위 10개)

| grid_gid | 위험 순위 | 위험 지수 | 핵심 인프라 공백 | 제안시설 | 우선순위 |
|---|---|---|---|---|---|
| 다사738470 | 1 | 310.16 | child_zone, speedbump, bus_stop, CCTV 계열 인프라 부족 | 방지턱+노면표시 | 1 |
| 다사757484 | 2 | 192.31 | 6종 전부 없음 | 어린이보호구역 보강 | 2 |
| 다사728472 | 3 | 189.01 | 6종 전부 없음 | 방지턱+노면표시 | 3 |
| 다사745480 | 4 | 169.37 | 6종 전부 없음 | 방지턱+노면표시 | 4 |
| 다사751480 | 5 | 159.48 | child_zone, CCTV 계열 인프라, bus_stop 없음 | 지능형 CCTV | 5 |
| 다사749487 | 6 | 155.51 | crosswalk, speedbump, CCTV 계열 인프라, bus_stop 없음 | 방지턱+노면표시 | 6 |
| 다사731477 | 7 | 151.96 | crosswalk, child_zone, speedbump, bus_stop 없음 | 방지턱+노면표시 | 7 |
| 다사742474 | 8 | 151.56 | crosswalk, child_zone, CCTV 계열 인프라, bus_stop 없음 | 스마트 횡단보도 | 8 |
| 다사734465 | 9 | 150.32 | crosswalk, child_zone, CCTV 계열 인프라 없음 | 스마트 횡단보도 | 9 |
| 다사750478 | 10 | 52.49 | 6종 전부 없음 | 방지턱+노면표시 | 10 |

*지도 2. 적정 시설물 제안*

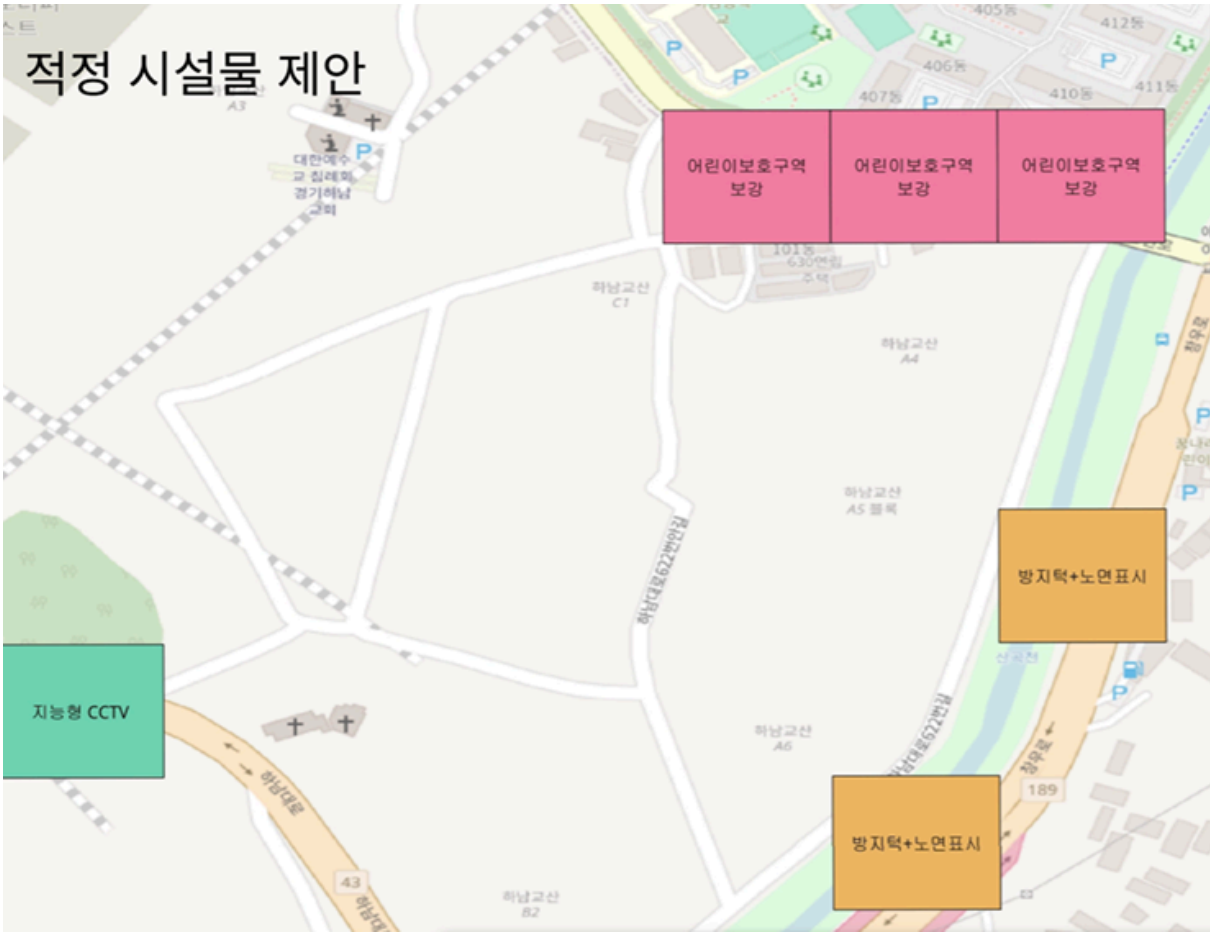


적정 시설물 제안

**지도·시각화 활용 가이드:** 본 절 결과를 지도에 표시할 경우, 4개 신도시·하남교산 각각에 대해 (1) 격자별 위험등급(고/중/저)을 색상으로 구분하고, (2) 고위험 구역은 붉은색, 중위험은 주황색, 저위험은 녹색 계열로 표시한다. (3) 인프라 공백이 중첩된 격자는 별도 마커 또는 패턴으로 강조하여 우선개입 후보를 한눈에 식별할 수 있게 한다.

### 7-3. 단계별 실행계획

*아래 단계는 7-2절 적정 시설물 제안 지도(지도 2)를 기준으로 한다.*

1단계(즉시) — 고위험 격자 집중 해소

- 지도 2 기준, 하남교산 고위험 9개 격자의 인프라 공백(횡단보도/CCTV/과속방지턱) 우선 해소
- 4개 신도시 Top 5% 고위험 격자 대상 동일 조치 병행

2단계(단기) — 저위험 격자 선별 보강

- 지도 2의 시설물 제안 격자 중, 하남교산 저위험 32개 격자 내 ECR 상위·인프라 공백 중첩 격자 집중 보강
- 하교·퇴근 시간대 단속 및 신호 운영 강화

3단계(중기) — 전체 격자 포괄 계획

- 노인 밀집 구역 보행안전(조명, 신호시간, 보행섬) 개선
- 지도 2의 시설물 제안 41개 격자 + 블록유형 기반 고위험 85개 격자를 통합하여 선제 배치 계획 수립
- 저위험 32개 격자 포함 전체 모니터링 체계 구축

## 8. 한계 및 후속 과제

- 본 분석은 “어디가 위험한가”를 순위로 보여주지만, “왜 위험한가”의 원인을 직접 증명하지는 못한다(상관관계 ≠ 인과관계).
- CCTV/방지턱은 이미 위험한 곳에 사후에 설치된 경우가 있어, “CCTV가 많을수록 사고가 많다”는 결과가 나올 수 있다. 이는 CCTV가 사고를 유발하는 것이 아니라 위험한 곳에 이미 설치되었기 때문이다.
- 1개 연도 데이터만 사용하였으므로, 여러 해에 걸친 검증과 시설 설치 전후 효과 비교가 필요하다.
- **임계값 재보정:** 위험등급 경계값(111.12, 77.38)은 4개 신도시 1,481격자 기준이다. 하남교산·다른 지역·다른 시점 데이터에 적용할 때는 해당 데이터의 분포에 맞게 재산출이 필요하다.
- **행정 제약 반영:** 예산·소유권·도로관리 주체 등 행정적 제약이 시설 배치에 영향을 준다. 분석 결과는 우선순위 제시용이며, 실제 배치 시 현장 조사·협의가 필요하다.
- **검증의 독립성 한계:** 6장 검증은 ECR과 EPDO 순위 일치율을 비교한다. 그런데 ECR 산식이 $\mathrm{EPDO} \times (1 + \mathrm{correction_index})$이므로, EPDO가 이미 ECR의 핵심 입력이어서 높은 상관은 수식 구조상 당연한 결과에 가깝다. 특정 연도 제외 후 예측 vs 실제, 또는 시설 설치 전후 효과 비교 같은 독립적 검증이 없으면 검증의 의미가 제한적이다.